

ZAAWANSOWANE ALGORYTMY WIZYJNE

Multi-Object Tracking

Mateusz Bielówka & Karol Bystrek & Patryk Chamera

PROBLEM

Tracking-by-detection

Dostajemy gotowe `bbox + confidence` na każdej klatce.

Zadanie: przypisać *stabilne ID* tej samej osobie przez całą sekwencję.

Wejście

per-frame detekcje z kwalifikacją pewności

Wyjście

trajektorie — każdy bbox otagowany trwałym `id`

Zaślnięcia & luki

osoba może zniknąć na kilka klatek i wrócić

Identity switch

skrzyżowanie torów → błędna zamiana ID

METRYKA

MOTA

$$\text{MOTA} = 1 - \frac{\text{FN} + \text{FP} + \text{IDSW}}{\text{GT}}$$

FN

False Negative
zgubiony obiekt GT

FP

False Positive
duch bez pokrycia w GT

IDSW

ID Switch
zmiana tożsamości

GT

Ground Truth
suma bboxów referencyjnych

Budowa trackera

01

Baseline — IoU + algorytm węgierski

Każda detekcja przypisana do najlepszego toru globalnie (minimalizacja sumy kosztów). IoU mierzy stopień nakładania bboxów — punkt startowy każdego trackera TBD.

02

Filtr Kalmana — predykcja ruchu

8-wymiarowy model stałej prędkości (pozycja + prędkość) przewiduje bbox na każdej klatce. Tor pozostaje aktywny nawet gdy detekcja chwilowo zanika (zasłonięcie, niska jakość kadru).

03

Koszt mieszany — IoU + znormalizowany dystans centroidów

Sama IoU zawodzi przy gęstych scenach — obiekty blisko siebie mają zbliżone nakładanie. Dodanie dystansu centroidów (skalowanego przekątną bboxów) pozwala odróżnić tory, które IoU traktuje identycznie.

04

Gating — trzy niezależne bramy akceptacji

Algorytm węgierski zawsze zwróci pary — nawet bezsensowne, gdy nie ma lepszych. Trzy bramy (min. IoU, max. dystans centroidów, max. koszt łączny) odrzucają przypisania poniżej progu jakości.

05

Dwuetapowa asocjacja — high-conf i low-conf

Podejście inspirowane ByteTrack: pewne detekcje (Etap 1) decydują o nowych torach, słabe (Etap 2) ratują *już potwierdzone* tory bez ryzyka tworzenia FP. Rozdzielenie ról zmniejsza jednocześnie FN i FP.

06

Grid search — systematyczna optymalizacja hiperparametrów

Kartezjański iloczyn 6 parametrów (648 kombinacji), każda uruchomiona na całym zbiorze treningowym. Kryterium: MOTA z lokalnego ewaluatora. Deterministyczny, w pełni odtwarzalny.

KOMPONENT

Filtr Kalmana

Rekurencyjny estymator stanu — łączy model ruchu (predykcję) z obserwacją (detekcją), ważąc je według ich niepewności. Dzięki predykcji tracker utrzymuje aktywny tor przez całe `max_age` klatek bez detekcji, zamiast natychmiast tracić obiekt. Model **stałej prędkości (CV)** — prosty, ale wystarczający dla ruchu pieszych.

WEKTOR STANU (8D)

```
x = [x, y, w, h, vx, vy, vw, vh]
```

Pozycja lewego górnego rogu + rozmiar bbox + ich prędkości. $\Delta t = 1$ klatka.

POMIAR (4D)

```
z = [x, y, w, h] ← tylko bbox z detekcji
```

MACIERZE MODELU

```
F → I8 + [pos ← pos + vel] na off-diag  
H → I4 | 04 (obserwujemy tylko pozycję)  
Q → diag: pos×0.05, vel×0.01  
R → I4 (szum pomiaru)  
P0 → 10·I8 (duża startowa niepewność)
```

Predykcja utrzymuje tor aktywny przez `max_age = 35` klatek bez detekcji. Po każdym kroku: `clamp w, h ≥ 1` (zapobiega degeneracji bbox).

KOMPONENT

Koszt asocjacji

Algorytm węgierski wyznacza **globalne optymalne przypisanie one-to-one** torów do detekcji — minimalizuje sumaryczny koszt, nie każdą parę z osobna. Łączymy dwa sygnały: *nakładanie bboxów* (IoU) oraz *odległość centroidów* — razem są bardziej odporne na błędne przypisania przy gęstych scenach niż samo IoU.

$$\text{cost} = w_{\text{iou}} \cdot (1 - \text{IoU}) + w_c \cdot d_{\text{norm}} \quad [w_{\text{iou}}=0.65, w_c=0.35]$$

NORMALIZACJA ODLEGŁOŚCI CENTRUM

```
d_norm = min(1,
    dist(c_track, c_det)
    / max(1, 0.5 * (diag_t + diag_d))
)
```

Skalowanie przekątną bboxów → miara niezależna od rozmiaru obiektu.

TRZY BRAMY (GATING) – PO PRZYPISANIU

$\text{IoU} \geq 0.15$ — minimalne nakładanie

$d_{\text{center}} \leq 1.6$ — maks. dystans centroidów

$\text{cost} \leq 0.92$ — łączny koszt

Pary poniżej progów → odrzucone jako unmatched, mimo wyniku Węgierskiego.

KLUCZOWY POMYSŁ

Asocjacja dwuetapowa

Podejście inspirowane **ByteTrack**: detekcje dzielimy według pewności i traktujemy różnie. Pewne detekcje budują nowe tory i wykonują główne przypisanie; słabe służą *wyłącznie* do ratowania już istniejących, potwierdzonych torów — bez ryzyka tworzenia FP z szumu detektora.

ETAP 1 — HIGH CONF

$\text{conf} \geq 0.30$

- Wszystkie aktywne tory vs detekcje high-conf
- Koszt mieszany: $w \cdot (1 - \text{IoU}) + w \cdot d_{\text{norm}}$
- Trzy bramy: IoU, dystans centrum, koszt łączny
- Niesparowane high dety → **nowe tory**



ETAP 2 — LOW CONF RECOVERY

$0.05 \leq \text{conf} < 0.30$

- Tylko *potwierdzone* tory ($\text{hits} \geq 3$) — bez nowych
- Tylko IoU (brama: $\text{IoU} \geq 0.60$, rygorystyczna)
- Niesparowane low dety → **odrzucone** (nie tworzą torów)

Rozdzielenie ról: Etap 1 zarządza nowymi bytami (FP/FN), Etap 2 ratuje zastłonięte / przejściowo słabe obiekty bez ryzyka tworzenia duchów.

CYKL ŻYCIA

Init • Confirm • Delete

Zarządzanie cyklem życia to filtr jakości torów: nowe tory muszą „udowodnić” istnienie przez kilka kolejnych klatek zanim pojawią się w wynikach (eliminacja FP z chwilowych błędów detekcji), a zbyt długo niewidziane tory są usuwane (uwalniamy ID, eliminujemy duchy).

INIT

Nowa high-conf detekcja bez pary tworzy tor.

`hits = 1`, `time_since_update = 0`.

Nie emitowany jeszcze w wynikach.



CONFIRMED

Tor pojawia się w wynikach gdy `hits ≥ min_hits (2)`.

Kwalifikuje do low-conf rescue (Etap 2) po `hits ≥ 3`.

Każda pomyślna asocjacja: `hits += 1`.



DELETED

Tor usunięty gdy `time_since_update > max_age (35)`.

Filtr Kalmana „trzyma” pozycję przez 35 klatek bez detekcji.

Zwolnione ID nie są ponownie używane.

Grid Search

Parametry wpływają na wzajemne kompromisy FN ↔ FP ↔ IDSW. Wybrałem przeszukiwanie siatki (vs random search) — przestrzeń jest mała, każdy wymiar mały, wynik deterministyczny.

PARAMETR	WARTOŚCI	ROLA
det_conf_threshold	[0.2, 0.25, 0.3]	próg high-conf → bilans FP/FN
det_low_conf_threshold	[0.05, 0.1, 0.15]	dolny próg Etapu 2
iou_match_threshold	[0.15, 0.2, 0.25]	rygor bramy IoU Etap 1
iou_match_threshold_low	[0.4, 0.5, 0.6]	rygor bramy IoU Etap 2
max_age	[30, 35]	przeżywalność toru bez detekcji
min_hits	[2, 3]	klatki do potwierdzenia emisji

3×3×3×3×2×2 = **648 kombinacji**. Kryterium: `overall["mota"]` z lokalnego ewaluatora.

NAJLEPSZA KONFIGURACJA

config/default.yaml

PROGI PEWNOŚCI

det_conf_threshold	0.30
det_low_conf_threshold	0.05

ASOCJACJA – ETAP 1

iou_match_threshold	0.15
max_center_distance	1.6
max_match_cost	0.92
weight_iou	0.65
weight_center_distance	0.35

ASOCJACJA – ETAP 2

iou_match_threshold_low	0.60
-------------------------	------

CYKL ŻYCIA

max_age	35
min_hits	2
save_only_confirmed	true

MOTA 50.3%

OVERALL MOTA

50.3%

FN

32 400

dominujący błąd

FP

3 553

IDSW

140

GT

72 638

SEKWENCJA	MOTA	FN	FP	IDSW
MOT_02	51.2%	21 344	1 853	0
MOT_03	49.1%	3 407	104	11
MOT_04	55.3%	2 363	12	3
MOT_05	45.5%	5 286	1 584	126

FN dominuje — tracker traci osoby zasłonięte lub słabo widoczne. MOT_05 ma więcej FP i IDSW: gęstsza scena.

WYNIKI – TEST (CODABENCH)

MOTA 42.4%

OVERALL MOTA

42.4%

FN
21 069
dominujący błąd

FP
1 344

IDSW
421

SEKWENCJA	MOTA	FN	FP	IDSW
MOT_01	32.7%	12 200	241	71
MOT_06	56.5%	3 848	195	57
MOT_07	46.6%	5 021	908	293

MOT_01 — scena o wysokiej gęstości, tracker traci więcej obiektów (FN dominuje). MOT_07 — wyraźnie więcej FP i IDSW: dynamiczna scena, częste skrzyżowania torów.

KONIEC

Dziękujemy za uwagę

Mateusz Bielówka & Karol Bystrek & Patryk Chamera