

ZAAWANSOWANE ALGORYTMY WIZYJNE

Multi-Object Tracking

Stabilne trajektorie osób z gotowych detekcji · EVS-MOT dataset

MOTA

50.3%

SEKWENCJE

4

KLATKI

3 066

GT BBOXÓW

72 638

PROBLEM

Tracking-by-detection

Detektor już działa — dostajemy gotowe `bbox + confidence` na każdej klatce. Zadanie: przypisać *stabilne ID* tej samej osobie przez całą sekwencję.

Wejście

per-frame detekcje z kwalifikacją konfidensu

Wyjście

trajektorie — każdy bbox otagowany trwałym `id`

Zaślnięcia & luki

osoba może zniknąć na kilka klatek i wrócić

Identity switch

skrzyżowanie torów → błędna zamiana ID

DANE

Format MOT

DET/DET.TXT – WEJŚCIE

```
<frame>, -1, bb_left, bb_top, bb_width, bb_height, conf
```

frame 1-based · $\text{conf} \in [0, 1]$ · współrzędne float

MOT_XX.TXT – WYJŚCIE

```
<frame>, id, bb_left, bb_top, bb_width, bb_height, 1, -1, -1, -1
```

trailing 1, -1, -1, -1 stałe · id unikalne w sekwencji

Train: gt/gt.txt dostępne

Test: **brak ground truth**

GT filtr: eval_flag=1 && class=1

METRYKA

MOTA

$$\text{MOTA} = 1 - \frac{\text{FN} + \text{FP} + \text{IDSW}}{\text{GT}}$$

FN

False Negative
zgubiony obiekt GT

FP

False Positive
duch bez pokrycia w GT

IDSW

ID Switch
zmiana tożsamości

GT

Ground Truth
suma bboxów referencyjnych

Ewaluacja lokalna: Hungarian @ IoU ≥ 0.5 per-frame. IDSW = zmiana pred-id dla tej samej GT-id między kolejnymi klatkami.

Jak budowałem tracker

01 Baseline IoU + Hungarian

minimalne FP/FN przez globalne przypisanie na każdej klatce

02 Filtr Kalmana

predykcja pozycji między klatkami — tracker przeżywa chwilowy brak detekcji

03 Koszt mieszany IoU + centroid

same IoU może mylić obiekty o podobnym nakładaniu; dystans centrów dodaje lokalizację

04 Gating

odrzucaamy pary, które Hungarian sparował "siłą" mimo dużego kosztu

05 Dwuetapowa asocjacja (high / low conf)

oddzielenie nowych torów od ratowania istniejących → mniej FP i FN jednocześnie

06 Grid search parametrów

iloczyn kartezjański 6 parametrów, MOTA jako kryterium

KOMPONENT

Filtr Kalmana

STAN (8D)

```
x = [x, y, w, h, vx, vy, vw, vh]
```

Model stałej prędkości (CV). $\Delta t = 1$ klatka.

POMIAR (4D)

```
z = [x, y, w, h]
```

MACIERZE

```
F → I8 + diag(1,1,1,1) na off-diag [0,4]..[3,7]  
H → I4 | 04 (picks x,y,w,h)  
Q → diag: pos×0.05 vel×0.01  
R → I4  
P0 → 10·I8 (duża niepewność)
```

Predykcja utrzymuje tor aktywny przez `max_age = 35` klatek bez detekcji. Clamp: `w, h ≥ 1` po każdym kroku.

KOMPONENT

Koszt asocjacji

$$\text{cost} = w_{\text{iou}} \cdot (1 - \text{IoU}) + w_c \cdot d_{\text{norm}}$$

NORMALIZACJA ODLEGŁOŚCI CENTRUM

```
d_norm = min(1,
    euclidean(c_track, c_det)
    / max(1, 0.5 · (diag_t + diag_d))
)
```

Skalowana przekątną bboxów → niezależna od rozmiaru.

TRZY BRAMY (GATING)

$\text{IoU} \geq \text{iou_threshold}$

$d_{\text{center}} \leq \text{max_center_distance}$

$\text{cost} \leq \text{max_match_cost}$

Para nie przejdzie bram → unmatched, nawet jeśli Hungarian ją wybrał.

KLUCZOWY POMYSŁ

Asocjacja dwuetapowa

ETAP 1 – HIGH CONF

$\text{conf} \geq 0.30$

- Wszystkie tory vs high detekcje
- Koszt mieszany: IoU + centroid
- Trzy bramy (IoU, center, cost)
- Nieużyte high dety → **nowe tory**



ETAP 2 – LOW CONF RECOVERY

$0.05 \leq \text{conf} < 0.30$

- Tylko *potwierdzone* tory (hits ≥ 3)
- Tylko IoU, brama `iou_low = 0.6`
- Nieużyte low dety → **odrzucone**

Rozdzielenie ról: Etap 1 decyduje o nowych bytach, Etap 2 ratuje znane tory bez tworzenia FP.

CYKL ŻYCIA

Init • Confirm • Delete

INIT

Nowa high-conf detekcja bez pary → nowy tor, `hits = 1`



CONFIRMED

`hits ≥ min_hits (2)`

Emitowany w wynikach.

Kwalifikuje do Etapu 2 przy `hits ≥ 3` (hardcoded).



DELETED

`time_since_update > max_age (35)`

Tor usunięty ze stanu trackera.

Uwaga: `min_hits` z YAML kontroluje *emisję* wyników (`save_only_confirmed = true`). Próg kwalifikacji do Etapu 2 to niezależny, hardcoded `hits ≥ 3` .

Grid Search

Parametry wpływają na wzajemne kompromisy FN ↔ FP ↔ IDSW. Wybrałem przeszukiwanie siatki (vs random search) — przestrzeń jest mała, każdy wymiar mały, wynik deterministyczny.

PARAMETR	WARTOŚCI	ROLA
det_conf_threshold	[0.2, 0.25, 0.3]	próg high-conf → bilans FP/FN
det_low_conf_threshold	[0.05, 0.1, 0.15]	dolny próg Etapu 2
iou_match_threshold	[0.15, 0.2, 0.25]	rygor bramy IoU Etap 1
iou_match_threshold_low	[0.4, 0.5, 0.6]	rygor bramy IoU Etap 2
max_age	[30, 35]	przeżywalność toru bez detekcji
min_hits	[2, 3]	klatki do potwierdzenia emisji

3×3×3×3×2×2 = **648 kombinacji**. Kryterium: `overall["mota"]` z lokalnego ewaluatora.

NAJLEPSZA KONFIGURACJA

config/default.yaml

PROGI KONFIDENSU	
det_conf_threshold	0.30
det_low_conf_threshold	0.05
ASOCJACJA – ETAP 1	
iou_match_threshold	0.15
max_center_distance	1.6
max_match_cost	0.92
weight_iou	0.65
weight_center_distance	0.35
ASOCJACJA – ETAP 2	
iou_match_threshold_low	0.60
CYKL ŻYCIA	
max_age	35
min_hits	2
save_only_confirmed	true

MOTA 50.3%

OVERALL MOTA

50.3%

FN
32 400
dominujący błąd

FP
3 553

IDSW
140

GT
72 638

SEKWENCJA	MOTA	FN	FP	IDSW
MOT_02	51.2%	21 344	1 853	0
MOT_03	49.1%	3 407	104	11
MOT_04	55.3%	2 363	12	3
MOT_05	45.5%	5 286	1 584	126

FN dominuje — tracker traci osoby zasłonięte lub słabo widoczne. MOT_05 ma więcej FP i IDSW: gęstsza scena.

PODSUMOWANIE

Modularny, mierzalny, odtwarzalny

Modularność

`mot/io · kalman · geometry · association · tracker · postprocess` — każda warstwa wymienialna niezależnie

Odtwarzalność

pełna konfiguracja w `config/default.yaml`; deterministic pipeline; CLI skrypty

Diagnostyka

lokalny ewaluator zwraca FN/FP/IDSW per-sekwencja — wiadomo gdzie tracić

Kolejne kroki

appearance features (Re-ID) do redukcji IDSW; interpolacja luk; submission na Codabench